

10 Experiment 1

- Vocabulary size & Matrix size: đều giữ nguyên ($|V| = 31$, matrix 31×31) vì khác từ vựng chỉ phụ thuộc vào ngữ liệu, không đổi theo window
- Number of non-zero values: Tổng liên tục ($74 \rightarrow 118 \rightarrow 158$; $7,7\% \rightarrow 16,4\%$) do window càng rộng càng thu nhận thêm nhiều từ ngữ cảnh, làm giảm độ thưa.

CRABIT

Similarity giữa các từ

→ doctor - physician: bất biến ở mức 1.000

→ đồng nghĩa hoàn toàn trong ngữ liệu

→ doctor - hospital: tăng dần (0,7716 → 0,8198)

do window lớn bất tốt môi liên hệ chủ đề xa

→ cat - dog: giảm nhẹ vì window nhỏ phản ánh tính thay thế cú pháp tốt nhất, còn window lớn bắt đầu bị pha loãng bởi ngữ cảnh xa & khác.

15. Skip-gram

- CBOW: → Input: là tập các từ ngữ cảnh

→ Target: là từ trung tâm

- Skip-gram: → Input: là từ trung tâm

→ Target: là các từ ngữ cảnh

16. CBOW vs Skip-gram

⊗ CBOW

- target: the → ["cat"] → "the"

- target: cat → ["the", "eats"] → "cat"

- target: eats → ["cat", "fish"] → "eats"

- target: fish → ["eats"] → "fish"

⊗ Skip-gram

- target: the → ("the", "cat")

- target: cat → ("cat", "the"), ("cat", "eats")

- target: eats → ("eats", "cat"), ("eats", "fish")

- target: fish → ("fish", "eats")

18. Inspect embeddings

- surgeon (Sim: 0,7572 | Freq: 117)

→ Context: 131 context chung

→ VD: "saw my first eye doc"

→ Evidence rất mạnh, hỗ trợ trực tiếp kết quả

- dentist (Sim: 0,7203 / Freq: 51)

+> Context: 54 context chung

+> VD: "talk with your doctor and dentist"

y tế

- physician (Sim: 0,7095 / Freq: 86)

+> context: 112 context chung

+> Evidence rất mơ hồ (đồng nghĩa / thay thế nhau qua nhiều ngữ cảnh)

- ophthalmologist (Sim: 0,6949 / Freq: 10)

+> context: 17 context chung

+> Evidence hỗ trợ tốt quan hệ chuyên khoa mắt & tư vấn

- veterinarian (Sim: 0,6912 / Freq: 20)

+> context: 23 context chung

+> Evidence hỗ trợ tốt nhóm hành động khám chữa bệnh.

19. Experiment 3

- Có 3 cặp đều giảm dần điều khi tăng window từ 2 lên 10. Vì Window nhỏ thì nhận ngữ cảnh cũ pháp / thay thế chốt chỗ, window lớn gồm thêm nhiều từ xa không liên quan gây nhiễu & làm loãng vector

- Window lớn hơn không luôn tốt hơn

+> Eviden thực nghiệm:

doctor - physician: giảm mạnh từ 0,737 $\Rightarrow$ 0,669

cat - dog: giảm mạnh từ 0,5563 $\Rightarrow$ 0,4481

+> Tăng window quá lớn làm embedding bị nhiễu làm suy giảm khả năng nhận diện các cặp từ có quan hệ đồng nghĩa / cú pháp chốt chỗ

20. Experiment 19

- Chi phí tính toán: Dimension tăng 50 $\rightarrow$ 300
mã dùng lg tăng 6 lần & train huấn
tăng hơn 2 lần
- Chất lượng mô hình: Không tăng theo chiều. Độ
tương đồng & điểm ~~similarity~~ analogy bị giảm
đần, trong khi độ chính xác bài toán downstream
& rank analogy giữ nguyên bảo hòa
- Kích thước Corpus: Không đủ lớn để tận dụng
dimension cao, dẫn $\rightarrow$ phân tán không gian vector
không cần thiết
- Trade-off: Dimension cao gây tốn bộ nhớ
& train tính toán mà không đem lại cải thiện
hiệu năng (Chỉ tập dữ liệu nhỏ, mức 50 là
tối ưu nhất).

21. Evaluation

- Ranking:
 - doctor - physician: 0,7095
 - king - queen: 0,6658
 - car - automobile: 0,6477
 - cat - dog: 0,5444
 - Computer - banana: 0,0321

- Intuition:

Kỳ vọng: car - automobile $\geq$ doctor - physician?
king - queen $>$ cat - dog $\gg$ computer - banana.

- TH bất ngờ

+> Car - automobile xếp hạng 3, thấp hơn king - queen
& doctor - physician

+> Evidence: automobile có tần số thấp, dẫn $\rightarrow$
H ngữ cảnh chung; trong khi king, queen thiên
cân =, chia sẻ ngữ cảnh duy nhất

+> KL: Mô hình tách biệt từ cặp từ liên quan ngữ
thức trong giữa các cặp trong đồng bị chỉ **CRABIT** phải
mạnh bởi tần số từ & ngữ cảnh corpus thay vì trực giác

22. Evaluation

③ king - man + woman (Expected: queen)

Top 5:

- 1: queen
- 2: beebing
- 3: headboard
- 4: chaps
- 5: princess

Expected answer: không ở Rank 1

④ paris - france + italy (Expected: rome)

Top 5:

- 1: tuscany
- 2: hampshire
- 3: vermont
- 4: piazza
- 5: loughrea

Expected answer: không trong Top-5

- Phép toán vector thể hiện đc quan hệ nhà tính chất bù trừ hướng tuyến tính khi ở cặp từ có sự chênh lệch phổ ngữ cảnh tương tự nhau trên dữ liệu

- Thất bại ở cặp từ đđ - quốc gia do corpus thiếu dữ liệu đồng nghĩa đặc thù, khiến vector trả về nhóm từ đánh chung.

- Word2Vec không "hiểu" ngữ nghĩa như con người, đây thuần túy là pattern phổ thống kê hình học trong kg vector.

27 Reflection:

	Context-	Sparse/	1 từ có nh
Representation	dependent	Dense	vector
TF-IDF	k_o	Sparse	k_o
Co-occurrence	k_o	Sparse	k_o
Word2Vec	k_o	Dense	k_o
Contextual Embedding	C_i	Dense	C_i

- Giải hạn static vector: Gán duy nhất 1 vector cho cả 2 nghĩa đầu lập là ngôn ngữ & từ vựng, làm vector bị nhiễu do pha trộn ngữ nghĩa

- Giải pháp Contextual: Sinh vector đồng thích ứng theo ngữ cảnh từng câu cụ thể, giải quyết triệt để vấn đề từ đa nghĩa